



ACIF104 Aprendizaje de máquina

Nombres:

JUAN CONDORI

NELSON CARRASCO ZEPEDA

RUBEN DELGADO ARRIAGADA

SEBASTIAN NUÑEZ SOTO

Curso: Ingeniería Civil Informática

Fecha: 06/07/2026

1. Problemática y análisis de trabajos previos

Definición de la Problemática:

El fraude en transacciones con tarjetas de crédito representa una de las mayores amenazas para la estabilidad y confianza del sistema financiero global. Con la migración masiva hacia el comercio electrónico y los pagos digitales, los patrones delictivos se han vuelto altamente sofisticados, camuflándose dentro del comportamiento transaccional legítimo. La problemática central radica en que los sistemas tradicionales basados en reglas estáticas son incapaces de procesar la alta dimensionalidad de los datos modernos, generando una excesiva cantidad de falsos positivos (bloqueos de tarjetas legítimas que frustran al usuario) o, en el peor de los casos, falsos negativos (fraudes no detectados que generan pérdidas millonarias).

Justificación y Relevancia (Análisis Crítico):

La implementación de Machine Learning (ML) se ha vuelto un estándar imperativo en la industria. Según Benchaji et al. (2021), el manejo del desbalanceo extremo de clases (donde el fraude representa menos del 0.5% del total) es el principal desafío, demostrando que técnicas de sobremuestreo sintético (como SMOTE) mejoran drásticamente la sensibilidad del modelo. Por su parte, Hilal et al. (2022) argumentan que el contexto geoespacial y el rubro comercial son variables más determinantes que el simple monto financiero. Ileberi et al. (2022) demostraron que la reducción de dimensionalidad (Feature Selection) es vital para evitar el colapso de los servidores al procesar millones de transacciones. A nivel organizacional, un modelo óptimo debe priorizar el Recall (Sensibilidad) por sobre el Accuracy, ya que el costo económico de dejar pasar un fraude es infinitamente mayor al de revisar manualmente una alerta (Makki et al., 2020). Finalmente, Al-Hawsawi (2021) destaca la necesidad de que estos modelos no sean "cajas negras", exigiendo explicabilidad técnica para cumplir con las normativas bancarias.

2. Requisitos del Proyecto

A partir del análisis de la problemática, se definen los siguientes requisitos para el sistema de detección:

1. Requisitos Funcionales:

- El sistema debe integrarse a un Data Warehouse (SQL Server) para la extracción automatizada de registros transaccionales.
- El sistema debe aplicar técnicas de preprocesamiento (One-Hot Encoding) y balanceo de datos (SMOTE) de forma dinámica.
- El modelo debe clasificar cada transacción entrante como "Legítima" (0) o "Fraude" (1) basándose en los metadatos de la tarjeta, cliente y comercio.

2. Requisitos No Funcionales:

- Usabilidad: El sistema debe entregar reportes y gráficos de validación fáciles de interpretar por analistas de ciberseguridad.
- Explicabilidad: El algoritmo debe ser capaz de justificar sus decisiones (Feature Importance), mostrando qué variables tienen mayor peso en las alertas de fraude.
- Escalabilidad: La arquitectura (motor de base de datos relacional + Python) debe soportar el entrenamiento eficiente con al menos 1.000.000 de registros sin incurrir en desbordamiento de memoria (Memory Overflow).
- Seguridad: Los datos sensibles de los usuarios (IDs) deben ser desestimados o anonimizados durante la fase de entrenamiento para resguardar la privacidad.
- Confiabilidad: El sistema debe manejar eficazmente el desbalanceo natural de la clase minoritaria, garantizando una alta tasa de Verdaderos Positivos (Recall).
- Monitoreabilidad: Se debe generar una bitácora técnica de rendimiento (Matriz de Confusión y Classification Report) en cada ciclo de entrenamiento.

3. Desarrollo inicial del proyecto

Para cumplir con los objetivos, se proponen y comparan tres técnicas de Machine Learning:

1. XGBoost (Extreme Gradient Boosting) - Aprendizaje Supervisado:

- Justificación: Es el estándar de la industria para datos tabulares altamente desbalanceados. Al construir árboles de decisión secuenciales donde cada uno corrige el error del anterior, es sumamente eficaz para capturar patrones de fraude complejos. Es nuestra opción principal debido a su optimización de hardware para escalar a millones de registros (Benchaji et al., 2021).

2. Random Forest - Aprendizaje Supervisado:

- Justificación: Funciona creando múltiples árboles de decisión paralelos (Bagging). Es excelente como modelo de referencia (baseline) y altamente explicable. Sin embargo, frente a un millón de datos y cientos de columnas (One-Hot Encoding), demanda excesiva memoria RAM en comparación con XGBoost.

3. Isolation Forest - Aprendizaje No Supervisado:

- Justificación: A diferencia de los anteriores, no utiliza las etiquetas de "fraude" previas. Busca anomalías aislando observaciones atípicas en el espacio multidimensional (Hilal et al., 2022). Se propone como respaldo en caso de que existan transacciones fraudulentas no etiquetadas previamente en la base de datos (Zero-Day Fraud).

Comparación: Para el contexto de este proyecto (donde poseemos etiquetas precisas de 0 y 1), las técnicas supervisadas son superiores. Entre ellas, XGBoost destaca sobre Random Forest al ofrecer un balanceo interno mediante Gradient Descent, lo que lo hace idóneo para los recursos computacionales definidos y la exigencia de alta métrica en Recall.

4. Desarrollo Inicial del Proyecto (Plan de Trabajo)

Para el cumplimiento del proyecto, se establece la siguiente carta de hitos, responsables y estimaciones:

Fase	Descripción	Responsable	Esfuerzo Estimado	Plazo
Fase 1: Configuración y Extracción	Modelado en SQL Server (Data Warehouse), normalización de tablas y extracción de muestra maestra.	Equipo completo	20 horas	Semanas 1 y 2
Fase 2: Análisis Exploratorio (EDA)	Limpieza, imputación de nulos, reducción de cardinalidad y graficación de correlaciones.	Equipo completo	25 horas	Semanas 2 y 3
Fase 3: Modelado y Balanceo	Aplicación de SMOTE, partición (Train/Val/Test) e implementación de XGBoost con métricas de rendimiento.	Equipo completo	20 horas	Semanas 3 y 4
Fase 4: Explicabilidad y Documentación	Extracción del Feature Importance, análisis de la matriz de confusión y elaboración del informe final institucional.	Equipo completo	15 horas	Semana 4 y 5

5. Referencias (APA 7ª Edición)

- Al-Hawsawi, A. (2021). A systematic literature review of machine learning techniques for credit card fraud detection. *IEEE Access*, 9, 116245-116258.
- Benchaji, I., Douzi, S., El Ouassif, B., & El Bakkali, J. (2021). Enhanced credit card fraud detection based on attention mechanism and SMOTE. *Expert Systems with Applications*, 167, 114175.
- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.^a ed.). O'Reilly Media, Inc.
- Hilal, W., Gadsden, S. A., & Yawney, J. (2022). Financial fraud: A review of anomaly detection techniques and recent advances. *Expert Systems with Applications*, 193, 116429.
- Ileberi, E., Sun, Y., & Wang, Z. (2022). A machine learning based credit card fraud detection using the GA algorithm for feature selection. *Journal of Big Data*, 9(1), 1-17.
- Makki, S., Assaghir, Z., Taher, Y., Haque, R., Hacid, M. S., & Zeineddine, H. (2020). An experimental study with imbalanced classification approaches for credit card fraud detection. *IEEE Access*, 7, 93010-93022.