



ACIF104 Aprendizaje de máquina

Nombres:

JUAN CONDORI

NELSON CARRASCO ZEPEDA

RUBEN DELGADO ARRIAGADA

SEBASTIAN NUÑEZ SOTO

Curso: Ingeniería Civil Informática

Fecha: 07/07/2026

1. Análisis Exploratorio de Datos (EDA) y Calidad del Dataset

Descripción y Calidad de los Datos:


Para la presente fase, se extrajo una muestra representativa de 1.000.000 de transacciones desde el Data Warehouse en SQL Server (vw_dataset_maestro). El análisis de completitud reveló una alta consistencia en las dimensiones financieras, requiriendo únicamente la imputación de nulos menores (relleno con 0) y la transformación de cadenas de texto monetarias (eliminación de símbolos '\$' y ',') a formato de coma flotante (float).

Para evitar la "Maldición de la Dimensionalidad" y posibles desbordamientos de memoria (Out of Memory) durante el One-Hot Encoding, se aplicó una técnica de Feature Selection eliminando variables de extrema cardinalidad, como merchant_city y merchant_id, conservando atributos categóricos de alto valor analítico como el uso de chip, género y rubro comercial (mcc_description).


Patrones Estadísticos y Visualizaciones:

El análisis exploratorio arrojó dos descubrimientos fundamentales:

- a. Distribución de Montos (Histograma): Se evidenció una asimetría positiva extrema (cola larga hacia la derecha), indicando que la inmensa mayoría de las transacciones son por montos bajos (compras cotidianas), mientras que las transacciones de alto valor son atípicas.



- b. Correlación Lineal (Mapa de Calor): Al cruzar las variables financieras (límite de crédito, deuda total, ingresos anuales) contra la variable objetivo (is_fraud), los coeficientes de correlación de Pearson resultaron cercanos a 0.00. Esto demuestra empíricamente que el fraude no guarda una relación lineal simple con el monto o el nivel de deuda de la víctima, justificando la necesidad de algoritmos predictivos no lineales.



2. Comparación de Técnicas de Machine Learning y Deep Learning

Para la arquitectura del modelo, se evaluaron diversas técnicas en función de su adaptabilidad a matrices ralas (producto del One-Hot Encoding) y al desbalanceo

Técnicas de Machine Learning (ML):

- Regresión Logística: Técnica paramétrica simple. Descartada rápidamente debido a que asume linealidad, algo que el Mapa de Calor demostró que no existe en este problema.
- Random Forest: Ensamblado basado en Bagging. Excelente métrica teórica, pero descartado debido a su ineficiencia en consumo de memoria RAM al procesar cientos de columnas generadas por variables categóricas.
- XGBoost (Extreme Gradient Boosting): Ensamblado secuencial. Seleccionado. XGBoost posee algoritmos internos optimizados para lidiar con matrices ralas y maneja el sesgo de datos de forma más eficiente, escalando computacionalmente sin saturar el entorno.

Arquitecturas de Deep Learning (DL):

- Multilayer Perceptron (MLP): Red neuronal densa (Fully Connected). Aunque es capaz de aproximar funciones no lineales complejas, en datos tabulares con alta varianza suele caer en sobreajuste (Overfitting) sobre la clase mayoritaria si no se aplican técnicas agresivas de Dropout.
- Autoencoders (Aprendizaje No Supervisado): Arquitectura de reconstrucción diseñada para detección de anomalías. Se entrena solo con datos "legítimos" y detecta el fraude por el error de reconstrucción. Descartado para esta fase ya que disponemos de un dataset completamente etiquetado, haciendo el aprendizaje supervisado más eficiente.
- TabNet: Arquitectura de Deep Learning basada en mecanismos de atención (Attention Mechanism), diseñada específicamente para datos tabulares. Descartada por restricciones computacionales, ya que su entrenamiento en CPU sobre 1 millón de registros resulta inviable para los plazos del proyecto.

3. Elaboración del Modelo, Muestreo y Balanceo de Clases

Partición del Dataset:

Se implementó una división estratificada (garantizando la misma proporción de la clase minoritaria) estructurada en: Entrenamiento (70%), Validación (15%) y Prueba (15%).

Análisis de Técnicas de Balanceo:

Dado que el fraude representa una fracción ínfima del dataset (clase 1), entrenar directamente produce la "Paradoja del Accuracy" (el modelo predice siempre 0 y obtiene 99% de precisión, pero Recall de 0%). Se evaluaron tres enfoques:

- in Balanceo (Baseline): Sesgo total hacia la clase mayoritaria. Inoperable para detección.
- Random Under-Sampling: Reducir la clase mayoritaria al tamaño de la minoritaria. Descartado, ya que, al contar con solo un puñado de fraudes reales, el modelo desecharía más del 99% de las transacciones legítimas, perdiendo información vital del comportamiento normal.
- SMOTE (Synthetic Minority Over-sampling Technique): Técnica Seleccionada. SMOTE opera en el espacio multidimensional, ubicando los casos de fraude reales y generando observaciones sintéticas mediante interpolación lineal (Vecinos Más Cercanos) hasta igualar la clase mayoritaria.

Resultados Iniciales:

La aplicación conjunta de XGBoost y SMOTE sobre el conjunto de entrenamiento generó una convergencia exitosa. Al evaluar contra el conjunto de validación, el modelo logró un Recall de 0.59; es decir, identificó correctamente cerca del 60% de los incidentes reales de fraude en una matriz de 1.000.000 de registros, marcando un hito técnico en la escalabilidad del proyecto.

4. Referencias

- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Géron, A. (2022). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow (3.^a ed.). O'Reilly Media, Inc.
- Lemaître, G., Nogueira, F., & Arcidascono, D. (2017). Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning. Journal of Machine Learning Research, 18(17), 1-5.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.